

탐색적 데이터 분석 (EDA)

iM뱅크 교육용 법인 익명데이터

대구·경북 법인 11,018곳 · 2023.01~2025.12

돈독(Don-Ddok) · iM DiGital Banker Academy 9기 통계 프로젝트

2026년 9월 30일

이 문서에 대하여

무엇인가. iM뱅크 교육용 법인 익명데이터를 분석에 쓰기 전·쓰는 동안 확인한 데이터 진단을 한곳에 모은 문서다.

왜 이 순서인가. 이 팀의 EDA는 "변수가 정의대로 작동하는가"를 확인하는 데 대부분의 시간을 썼고, 그 결과로 설계를 여러 번 바꿨다. 한도소진율을 버린 것, 금융·보험업을 뺀 것, 대조군을 수도권에서 지역 내부로 옮긴 것이 모두 EDA에서 나왔다. 그래서 이 문서는 기술통계 나열이 아니라 **"무엇을 발견해 무엇을 바꿨는가"**의 기록이다.

언제 한 것인가. 일부는 분석 착수 전에(소진율·금융업 제외), 일부는 분석 중에(환율 파일 오류, 규모 구성) 이뤄졌다. 과정 6일차 EDA 양식에 맞춰 모으면서 **수치는 전부 2026-09-30에 다시 계산해 확인했다.**

재현. 스크립트 `팀EDA/eda0_columns.py ~ eda8_figures.py`. 원본과 파생 패널은 은행 제공 자료라 로컬에만 두고, 이 문서에는 집계 결과만 실는다. 법인 단위 값과 법인ID는 없다.

0. 한 장 요약

확인한 것	핵심 수치	바뀐 것
표본 범위	전국 365,988행 → 분석 표본 271,460행 / 11,018곳	대구·경북 한정, 금융·보험업 제외
분포	왜도 39~178 , 계정 절반이 중앙값 0	로그 변환, 계정 보유 법인으로 한정
측정 한계	유효숫자 2자리 반올림, 운전자금 월간 73.2% 무변동	보수적 추정임을 명시
못 쓰는 변수	좌수·건수 29개(구간 문자열), 사업장_시군구(시도 단위)	분석에서 제외
두 집단 차이	짜짓기 전 SMD 0.65~0.80 (기준 0.1)	성향점수매칭 도입
변수 정의 실패	한도소진율, 규모, 퇴직연금, 주택자금, 카드 2023-01	중속변수·공변량 교체
외부 데이터	수출↔영업일수 0.54 , 대구↔경북 -0.22	달력 통제, 지역별 분리

EDA 한 줄 결론. 주어진 컬럼을 그대로 썼다면 "대구·경북 법인의 절반이 한도를 초과해 쓰고 있다"는 잘못된 결론을 내고, 퇴직연금을 두 번 세고, 카드 계수를 2.7배 부풀렸을 것이다.


1. 데이터와 표본

1-1. 원자료

항목	내용
파일	(iM뱅크) 2026 교육용 법인 익명데이터.xlsx
규모	365,988행 × 70열, 법인 15,473곳
기간	2023.01 ~ 2025.12 (36개월)
단위	법인 × 월. 법인당 평균 23.7개월
금액	백만원 단위 추정, 유효숫자 2자리 반올림
중복	법인×월 중복 0건

열 이름을 먼저 확인한 결과 **공급 목록과 실제 파일이 다른 열이 두 개** 있었다. 목록의 **법인 신용카드사용금액 · 법인 체크카드사용금액** 이 실제로는 **신용카드사용금액 · 체크카드사용금액** 이다.

1-2. 표본을 좁힌 과정



단계	행	법인	근거
전국 전체	365,988	15,473	
대구·경북	271,915	11,036	지방은행 데이터라 다른 지역 고객은 자기선택된 특수 집단
금융·보험업 제외	271,460	11,018	업종 성격이 다름

금융·보험업은 대구·경북에서 **455행 / 18곳**이다.

정정이 필요한 근거. 기존 문서는 금융·보험업을 "전체 통계를 지배한다"는 이유로 제외한다고 적었다. 확인 결과 그 근거는 **전국 기준**이다(요구불 평균이 나머지의 31.7배). **대구·경북에는 18곳뿐이라 제외해도 전체 평균이 0.3~2.2%만 바뀐다.** 제외 결정 자체는 타당하지만(업종별 비교·매칭에서 이질적 집단을 섞지 않기 위해), 근거 문장은 고쳐야 한다.

방향성 문서와 중간보고서의 법인 수 차이(11,036 vs 11,018)도 **이 18곳**임이 확인됐다. 그동안 "유력"으로 남아 있던 항목이다.

1-3. 표본 정의

정의	법인	비중
분석 표본	11,018	100%
외환노출 (36개월 중 수출 또는 수입 실적 1회 이상)	1,032	9.4%
수출노출 (수출 실적만)	523	4.7%
운전자금 보유 이력	9,528	86.5%
균형패널 (36개월 전부 관측)	2,692	24.4%

수출 여부를 **업종 이름으로 짐작하지 않고 실제 외환 거래 기록으로** 정의한 것이 이 설계의 식별 근거다.


1-4. 결측

전국 기준 결측이 있는 열은 두 개뿐이다.

열	결측 행	법인
사업장_시도	12,424	474
사업장_시군구	12,424	474

지역이 비어 있는 법인은 대구·경북 필터에서 자연스럽게 빠진다. 금액 열에는 결측이 없고, 모두 숫자형으로 저장돼 있다.

1-5. 패널 구성 변화 — 매달 같은 법인을 보는 것이 아니다



항목	값
월별 관측 법인 수	7,257 ~ 7,777 (평균 7,541)
월평균 신규 진입	362곳
월평균 이탈	373곳
36개월 내내 관측	2,692곳 (24.4%)

매달 법인의 약 5%가 바뀐다. 전체 법인 수는 완만하지만 구성이 계속 교체된다.

이것이 이 프로젝트의 분석 원칙 하나를 만들었다.

평균 변화 = 같은 법인의 변화 + 입·퇴 교체 효과

평균·합계 추이를 그대로 결론으로 쓰지 않고, 지속·진입·퇴출 분해나 법인 고정효과를 함께 쓰는 이유다.

2. 기술통계

2-1. 계정별 기술통계량


분석 표본 271,460행 기준.

계정	보유 법인%	0인 행%	평균	중앙값	표준편차	p95	최대
요구불예금	97.2	9.4	120.9	7.4	800.9	460	75,000
거치식예금	7.6	94.6	61.4	0.0	1,261.9	11	200,000
적립식예금	6.0	95.6	3.9	0.0	44.3	0	3,400
수익증권	1.8	98.5	0.9	0.0	25.9	0	2,900
신탁	22.2	77.4	135.2	0.0	1,788.1	370	196,000
퇴직연금	19.5	80.0	76.2	0.0	559.2	280	27,000
운전자금대출	86.5	18.5	694.9	130.0	3,730.9	2,300	245,000
시설자금대출	30.4	69.7	664.8	0.0	2,755.9	3,300	91,000
여신한도	38.6	58.7	485.9	0.0	3,726.0	1,500	213,000
할인어음	3.4	98.0	4.3	0.0	80.4	0	8,100
무역금융	1.5	98.7	27.2	0.0	489.1	0	28,000
신용카드사용	70.8	32.7	4.9	1.3	26.6	18	7,200
요구불입금	97.8	9.4	497.2	60.0	3,977.6	1,400	580,000

중앙값이 0인 계정이 절반이다. 대부분의 법인에게 그 계정이 아예 없다.

요구불예금은 평균 120.9인데 중앙값이 7.4로 **16배 차이다**. 평균은 소수 대형 법인이 끌어올린 값이라 대표값이 아니다.

2-2. 분포 모양



계정	왜도(원값)	첨도(원값)	왜도(log1p)	왜도(양수만 log)
요구불예금	39.1	2,430	0.52	-0.37
운전자금대출	26.8	1,115	-0.48	-0.21
거치식예금	69.2	7,973	4.62	-0.16
신용카드사용	122.9	26,069	0.82	-0.76
외환 수입실적	177.5	39,710	25.0	0.55

왜도 0이 좌우 대칭, 첨도 0이 정규분포다. **원값은 왜도 39~178로 정규분포와 아주 멀다.**

여기서 두 가지 설계가 한꺼번에 정당화된다.

첫째, 왜 로그를 쓰는가. 로그를 씌우면 요구불 왜도가 39.1 → 0.52로 내려간다.

둘째, 왜 "그 계정을 보유한 법인으로 한정"하는가. 거치식을 보면 분명하다.

원값	왜도 69.2	
log(잔액+1)	왜도 4.62	← 0이 94.6%라 여전히 비뚤어짐
양수만 log	왜도 -0.16	← 거의 완벽한 좌우 대칭

0이 많은 계정은 로그를 씌워도 퍼지지 않는다. 보유 법인으로 한정해야 비로소 정규분포에 가까워진다. 팀이 "계정마다 그 계정을 한 번이라도 보유한 법인으로 표본을 한정한다"는 규칙을 쓴 통계적 근거가 이것이다.

정규성 검정에 대하여. D'Agostino 검정 p값은 모두 0이었다. 표본이 27만 개라 아주 작은 차이도 기각되어 **의미가 없다.** 5,000개 무작위 부분표본으로도 마찬가지였다. 판단은 검정 p가 아니라 왜도·첨도 크기와 0 비율로 한다.

2-3. 반올림 격자

은행이 유효숫자 2자리로 반올림해 제공했다는 것을 직접 확인했다.

계정	양수 관측	고유값 수	유효숫자 2자리와 일치
요구불예금	246,055	499	100.00%
운전자금대출	221,235	548	99.99%
시설자금대출	82,237	411	100.00%
거치식예금	14,624	296	100.00%

24만 개 관측인데 서로 다른 값이 499개뿐이다.

작은 변화는 애초에 관측되지 않는다. 효과를 작게 잡는 방향이므로 **이 데이터의 추정**은 보수적이다.

2-4. 무변동 비율

계정	월간(전체)	3개월(보유 법인)	6개월(보유 법인)
요구불예금	14.2%	6.9%	5.8%
운전자금대출	73.2%	61.9%	52.4%
시설자금대출	97.1%	83.4%	76.6%

운전자금은 월간 73.2%가 움직이지 않는다. 6개월을 봐도 절반 이상이 그대로다($\pm 5\%$ 기준). 시설자금은 분할상환 구조라 97%가 무변동이다.

반면 **요구불예금은 월간 무변동이 14.2%뿐**이다. 매달 움직이는 계정이고, 팀이 요구불에서 반응을 찾은 배경이기도 하다.

파트 3 문서의 6개월 무변동 54.2%와 이 표의 52.4%는 계산 방식 차이다(로그차분 +1 포함 여부, 직전 잔액 0 처리). 어느 쪽이 틀린 것이 아니다.

2-5. 범주형 변수 빈도 (회사 단위 11,018곳)

변수	값 개수	분포
사업장_시도	2	대구 6,107(55.4%) / 경북 4,911(44.6%)
법인_고객등급	3	일반 38.9% / 최우수 34.5% / 우수 26.6%
전담고객여부	2	Y 66.8% / N 33.2%
업종_대분류	17	제조업 33.4% / 도소매 18.7% / 건설 15.6%
업종_중분류	59	도매·상품중개 13.6% / 전문직별 공사 10.0%

업종 중분류 59개 중 **법인 20곳 미만인 8개(합계 107곳)**다. 짝짓기에서 20곳 미만을 '기타'로 묶은 이유다.

업종 대분류는 금융·보험업 제외 후 **17개**다. 기존 문서의 "18개"는 제외 전 숫자다.

2-6. 분석에 쓸 수 없는 변수

좌수·건수 29개 열 — 구간 문자열

요구불예금좌수	법인-월
2개초과 5개이하	86,772
2개	76,881
1개	57,382
5개초과 10개이하	36,074
10개초과 20개이하	10,924

'2개초과 5개이하'는 숫자가 아니라 구간 이름이다. 평균·차분·상관을 계산할 수 없다. 순서만 살려 순서형으로 써도 구간 폭이 **1, 1, 3, 5, 10, 10, 10, 10, 10, ∞**로 제각각이라 비교가 왜곡된다.

사업장_시군구 — 실제로는 시도 단위

전국 기준 고유값이 13개인데 전부 시도 이름이다.

강원특별자치도, 경기도, 경상남도, 경상북도, 대구광역시, 대전광역시, 부산광역시,
서울특별시, 울산광역시, 인천광역시, 전북특별자치도, 충청남도, 충청북도

열 이름은 시군구인데 내용은 시도다(공급 목록 예시에는 "경산시"로 되어 있어 더 헷갈린다). **구미·포항·경산 같은 단위의 분석은 불가능하다.** 지역 축을 대구/경북 둘로만 쓴 이유다.

2-7. 입금·출금과 잔액의 관계

데이터 설명서에 잔액의 기준 시점(월말인지)과 입출금의 집계 단위(월 합계인지)가 명시돼 있지 않아 직접 확인했다.

지표	값
피어슨 상관 (잔액변화 vs 입금-출금)	0.589
스피어만 상관	0.800
부호 일치	76.4%
(입금-출금) ÷ 잔액변화 중앙값	1.00 (p25 0.80 / p75 1.09)


비율 중앙값이 정확히 1.00이다. 잔액이 월말 값이고 입금·출금이 그 달 합계라면 나와야 하는 값이므로, 정의가 확인됐다.

피어슨이 0.589로 낮은 것은 극단값 때문이다. 순위로 보면 0.800이고, 절반이 0.80~1.09 안에 들어온다.

다만 이것이 "요구불 감소의 경로가 입금 감소다"를 뜻하지는 않는다. 변수 정의가 확인됐을 뿐이다.

3. 그룹별 비교

3-1. 외환노출 vs 비노출



계정	보유율 노출/비노출	평균 노출/비노출	배수
무역금융	11.2% / 0.5%	226.9 / 3.2	70배
거치식예금	16.9% / 6.7%	301.6 / 32.5	9.3배
요구불입금	99.8% / 97.6%	1,673.6 / 355.7	4.7배
할인어음	10.7% / 2.6%	14.6 / 3.1	4.7배
운전자금대출	95.0% / 85.6%	2,180.6 / 516.3	4.2배
요구불예금	99.2% / 97.0%	329.5 / 95.9	3.4배
시설자금대출	47.5% / 28.6%	1,216.7 / 598.5	2.0배

노출 법인은 모든 계정에서 크다. 박스플롯에서 상자가 통째로 올라가 있다.

예외가 하나 있다. **시설자금대출은 두 집단의 분포가 거의 같다**(중앙값 $\log_{10}$ 2.97 vs 3.07). 가진 회사끼리는 크기가 비슷하다는 뜻이다.

3-2. 짝짓기 전 두 집단 차이 (SMD)

변수	운전자금 보유 9,528곳	전체 11,018곳
첫 3개월 수신(로그)	0.735	0.700
첫 3개월 운전자금(로그)	0.650	0.690
최우수 등급	0.804	0.747
거래기간	0.366	0.371
우수 등급	-0.193	-0.186

SMD는 두 집단 차이를 "원래 흩어진 정도"로 나눈 값이라 단위가 달라도 같은 잣대로 비교된다. **기준이 0.1인데 0.65~0.80이다.**

두 집단은 "조금 다른" 정도가 아니라 **다른 집단**이다. 성향점수매칭을 도입한 직접 근거다.

3-3. 어떤 법인이 노출되는가 — 교차표

검정과 효과크기는 **회사 단위**로 계산했다. 회사×월 행으로 세면 같은 회사가 최대 36번 들어가 독립성 가정이 깨진다.

변수	카이제곱	p	Cramér's V
업종 대분류	938.3	1.8e-189	0.292
고객등급	530.4	6.7e-116	0.219
전담고객여부	251.6	1.2e-56	0.151
지역	31.6	1.9e-08	0.054

p값은 네 개 다 사실상 0이다. 표본이 커서 아주 작은 차이도 유의하게 나온다. 그래서 효과크기(Cramér's V)로 봐야 한다.

- **업종(0.29)과 등급(0.22)이 노출 여부와 가장 강하게 얽혀 있다.** 짝짓기에서 반드시 맞춰야 한다.
- **지역(0.05)은 거의 관련이 없다.**



구체적인 쓸림은 다음과 같다.

집단	노출 비율		집단	노출 비율
제조업	20.6%		최우수	18.0%
도매·소매업	9.4%		우수	6.9%
정보통신업	4.9%		일반	3.5%
건설업	1.8%			
부동산업	0.3%		전담고객 Y	12.5%
			전담고객 N	3.1%

제조업과 부동산업의 노출 비율이 **70배** 차이다.

짜짓기를 하지 않고 비교하면 "수출 회사 vs 비수출 회사"가 아니라 "**제조업 최우수 전담고객 vs 부동산업 일반 비전담**"을 비교하게 된다.

3-4. 업종·지역·등급별 분포



지역별

	법인	노출%	제조업%	운전 중량
경북	4,911	11.1%	44.5%	190.0
대구	6,107	8.0%	24.5%	100.0

경북은 제조업 비중이 대구의 1.8배다.

등급별

등급	법인	노출%	요구불 중량	운전 중량
일반	4,289	3.5%	0.6	48.0
우수	2,930	6.9%	9.2	190.0
최우수	3,799	18.0%	67.0	480.0

최우수와 일반의 요구불 중량값이 112배 차이다. 등급이 신용도라기보다 규모를 대신하고 있을 가능성이 있다. 분석에서 "등급이 반응을 가른다"는 관찰이 나왔을 때 탐색적 관찰로만 적은 것이 적절했다.

3-5. 관측 기간과 처치 과소식별

관측 기간	법인	비중	외환노출 비율
1~6개월	1,311	11.9%	3.6%
7~12개월	1,061	9.6%	4.9%
13~24개월	2,197	19.9%	8.3%
25~35개월	3,757	34.1%	14.7%
36개월(균형)	2,692	24.4%	7.3%

짧게 관측된 법인일수록 노출로 잡힐 확률이 낮다(3.6% → 14.7%). 수출을 해도 관측 기회가 적어 놓친 것이다.

처치 과소식별은 효과를 0 쪽으로 희석하므로 보수적 방향이다.

균형패널로 좁히면 노출 법인이 크게 줄어, 주 표본을 전체 관측 법인으로 정한 근거가 된다.

3-6. 그룹 차이 종합

항목	외환노출	비노출	배수
법인 수	1,032	9,986	
제조업 비율	73.4%	29.3%	2.5배
최우수 등급	66.2%	31.2%	2.1배
전담고객 Y	89.0%	64.5%	1.4배
경북 비율	52.9%	43.7%	1.2배
평균 관측 개월	28.2	24.3	1.2배
요구불 중앙값	62.4	12.5	5.0배
운전자금 중앙값	575.1	98.9	5.8배


노출 법인의 73%가 제조업이고 66%가 최우수 등급이다. 비노출은 각각 29%, 31%다. 이 표 하나가 짝짓기의 필요성을 전부 설명한다.


4. 상관분석

4-1. 계정 간 상관 — 전체와 회사 내가 다르다

패널 데이터에서 상관을 회사×월 행으로 그냥 계산하면 "큰 회사는 모든 계정이 크다"는 규모 효과가 지배한다. 법인 평균을 뺀 회사 내 변동으로도 계산해 함께 봤다. 회귀(법인 고정효과)가 실제로 쓰는 것은 후자다.

계정 쌍	스피어만(전체)	피어슨 로그(전체)	피어슨 로그(회사 내)
요구불입금 ↔ 요구불출금	0.942	0.940	0.676
요구불 ↔ 요구불입금	0.539	0.562	0.259
요구불 ↔ 신용카드	0.319	0.319	0.047
수출실적 ↔ 무역금융	0.302	0.305	0.054
수출실적 ↔ 수입실적	0.254	0.213	0.098
운전자금 ↔ 여신한도	0.243	0.180	0.091
요구불 ↔ 운전자금	0.087	0.026	-0.102





전체 상관의 대부분이 회사 간 차이였다. 회사 내로 바꾸면 거의 0으로 떨어진다. 히트맵에서 요구불 3형제(잔액·입금·출금)를 빼면 거의 전부 흰색이다.

두 가지가 눈에 띈다.

수출실적 ↔ 무역금융이 0.302 → 0.054로 무너진다. "무역금융은 수출과 기계적으로 연결된다"는 추론이 데이터로 확인되지 않았던 이유가 여기 있다. 회사 간 차이(수출하는 회사가 무역금융을 쓴다)를 회사 내 동조로 착각했던 것이다.

요구불 ↔ 운전자금이 회사 내에서 음수(-0.102)로 뒤집힌다. 통장이 빠지는 달에 대출이 조금 늘어난다. "통장 ↓ + 대출 유지 = 유동성 보전" 해석과 같은 방향이지만 -0.1은 아주 약하다.


4-2. '규모'는 사실 대출이다

지표	값
규모(수신+여신)에서 여신 비중 중앙값	95.3%
규모 ↔ 여신합 순위상관	0.927
규모 ↔ 수신합 순위상관	0.538

종속변수가 운전자금대출인데, 규모로 짝을 지으면 **결과 변수로 짝을 짓는 셈**이다. 게다가 대출이 규모를 지배해 예금 차이가 가려진다.

→ 짝짓기 기준을 **첫 3개월 수신·운전자금(따로)**으로 교체했다.

4-3. 외부 변수



상관 (2023~2025 월별)	경북	대구
수출YoY ↔ 영업일수 전년차	+0.365	+0.535
수출YoY ↔ 환율YoY	-0.076	+0.070
수출YoY ↔ 수입YoY	-0.038	+0.877
대구 수출YoY ↔ 경북 수출YoY	-0.218	
수출YoY 표준편차	9.0	18.5
수출 전년비가 마이너스인 달	26/36	22/36

세 가지가 설계에 반영됐다.

1. 수출과 영업일수의 상관이 0.54(대구)다. 같은 달의 동조가 경기가 아니라 달력일 수 있다. → 달력(영업일수) 통제 도입.
2. 두 지역 수출이 따로 논다(-0.22). 변동성도 2배 차이다(18.5 vs 9.0). 하나로 합치면 신호가 상쇄된다. → 지역 별로 따로 처리.
3. 수출과 수입의 관계가 지역마다 정반대다. 대구 +0.877(가공무역 성격), 경북 -0.038(무관). 처치를 "수출 또는 수입"으로 합쳤는데, 경북에서는 서로 다른 두 집단을 합친 셈일 수 있다. → 한계로 명시.

4-4. 지역 수출이 개별 업황을 대표하는가

지역	업종	법인	상관	하락 판정 일치%
경북	자동차·트레일러	254	-0.16	52.8
경북	금속 가공제품	252	0.37	61.1
경북	기타 기계·장비	252	0.00	52.8
대구	기타 기계·장비	239	0.53	75.0
경북	식료품	232	0.66	63.9
대구	섬유제품	206	0.16	50.0
경북	화학 물질	171	0.50	80.6
경북	1차 금속	137	0.13	52.8

전체 41개 지역×업종: 상관 중앙값 **+0.22**(범위 -0.32 ~ +0.70), 하락 판정 일치율 평균 **56.9%**.

두 지표가 무관해도 우연히 52.3%는 겹친다. 일치율이 우연보다 4.6%p 높을 뿐이다.

경북 자동차는 지역 수출이 26개월 하락했는데 생산 하락은 15개월뿐이고, 상관이 오히려 음수다.

→ 집계 수출은 개별 업종의 업황을 잘 대표하지 못한다. 업종 생산지수를 별도 충격으로 쓰는 근거다.

4-5. 범주형-연속형 연관성

분포가 심하게 치우쳐 있어 순위 기반 Kruskal-Wallis를 썼고, 효과크기 ϵ^2 를 병기했다.

범주형	연속형	p	ϵ^2	크기
등급	요구불	~0	0.265	큼
전담고객	요구불	~0	0.162	큼
업종	운전자금	~0	0.114	보통
등급	운전자금	~0	0.113	보통
전담고객	운전자금	~0	0.085	보통
업종	요구불	~0	0.026	작음
지역	운전자금	~0	0.006	없음
지역	요구불	0.017	0.0004	없음

지역 × 요구불이 이 표의 교훈이다. $p = 0.017$ 로 "유의"한데 ϵ^2 는 0.0004로 잔액 차이의 ****0.04%****밖에 설명하지 못한다.

기획 단계에서 팀이 적어 둔 우려 — "표본이 매우 커 미세한 차이에도 p-value가 유의하게 도출되는 왜곡 위험" — 의 실제 사례다. 효과크기를 병행하기로 한 계획이 제 역할을 했다.

등급(0.265)이 업종(0.026)보다 요구불을 10배 잘 설명한다. 3-4의 "등급 ≈ 규모"와 같은 이야기다.

5. 다중공선성과 변수 정의 검증

이 절은 "변수가 서로 겹치는가"를 넘어 "변수가 정의대로 작동하는가"를 본다. 설계를 바꾼 여섯 가지 근거를 전부 다시 계산했다.

5-1. 한도소진율이 성립하는가 — 주 종속변수를 바꾼 이유

항목	값
한도 > 0 인 행	41.3%
한도 = 0 인데 대출 > 0 인 행	48.6%
소진율 중앙값	1.0000
소진율 > 1 비율	46.2%
소진율 90분위 / 최댓값	6.10 / 1,571.4
정확히 1.0인 행	5.8%

분자와 분모가 다른 모집단을 재고 있다. 운전자금대출잔액은 한도 개념이 없는 증서대출까지 포함한 전체 잔액이고, 여신한도금액은 한도거래 약정자만의 약정액이다.

중앙값이 정확히 1.000인 이유도 확인됐다. **반올림 격자(고유값 500개 남짓) 위에서 분자와 분모가 같은 값으로 뭉쳐 우연히 겹친 것이다**(정확히 1.0인 행이 5.8%).

검증 없이 썼다면 "대구·경북 법인의 절반이 한도를 초과해 쓰고 있다"는 잘못된 결론이 나오고, 한도가 0인 표본 6할을 버린 채 분석하게 됐을 것이다.

→ 소진율은 어떤 분석에도 쓰지 않는다. 주 종속변수를 운전자금대출잔액의 로그 증감률로 교체했다.

정정이 필요한 수치. 기존 문서의 소진율 진단표에 "한도 > 운전자금 인 행 0.5%"가 있는데, 실제로는 19.8%(전체) / 48.0%(한도>0 행 중)다. 같은 표의 "소진율 > 1 이 46.1%"와도 앞뒤가 맞지 않는다. 다른 여섯 개 수치는 소수점까지 재현됐다.

5-2. 합계가 하위 항목의 합인가

	정확히 일치	1% 이내	로그 상관
운전자금 = 하위 8개 합	95.3%	97.1%	0.9995
시설자금 = 하위 4개 합	97.7%	98.6%	0.9984

사실상 항등식이다. 합계와 하위 항목을 같은 회귀에 넣으면 완전공선성이 생긴다. → 세부 항목 분석은 항목별로 따로 추정한다.

5-3. 퇴직연금이 신탁에 포함되는가

항목	값
퇴직연금 > 0 인 행	54,231
그중 신탁과 값이 같은 행	90.3%
그중 신탁 ≥ 퇴직연금인 행	100.0%

신탁이 퇴직연금보다 작은 경우가 한 건도 없다. 포함 관계가 확실하다. → 두 계정을 합산하면 이중계상이 된다.

5-4. 주택자금 두 열이 같은가

항목	값
운전_주택자금 = 시설_주택자금 인 행	100.00%
0인 행	99.95%
0이 아닌 행	133개 (법인 9곳)

271,460행 중 한 행도 예외 없이 같다. → 두 변수 모두 제외.

5-5. 카드 2023-01

ym	신용카드 평균	0인 비율
202301	0.00	100.00%
202302	4.43	29.24%
202303	5.05	27.63%
202512	5.09	32.35%

2023년 1월만 예외 없이 0이고 다음 달부터 29%로 떨어진다. 실제로 안 쓴 게 아니라 집계되지 않은 구간이다. 체크카드도 같다.

0으로 두면 그 달이 "지출 없음"으로 들어가 계수가 부풀려진다(팀 확인: 미처리 시 2.7배 과대). → 결측 처리.

5-6. VIF

짜짓기에 실제로 쓴 공변량 5개

변수	R ²	VIF
최우수	0.505	2.02
우수	0.276	1.38
첫 3개월 수신	0.245	1.33
첫 3개월 운전자금	0.184	1.23
거래기간	0.120	1.14

전부 2 이하로 서로 겹치지 않는다.

여기에 '규모'를 더 넣으면


변수	VIF(기존)	VIF(규모 추가)
첫 3개월 운전자금	1.23	2.78
첫 3개월 수신	1.33	1.69
log_규모	—	4.38

규모의 95%가 대출이니 당연하다. 규모를 뺀 판단이 숫자로 뒷받침된다.

주 회귀의 설명변수는 4개뿐이다(수출YoY, 수출YoY×노출, 연도 더미 2개). 변수를 적게 쓴 것은 다중공선성 때문이 아니라, 충격이 지역×월 2개 시계열뿐이라 통제를 늘릴수록 식별에 쓸 변동이 줄기 때문이다.

6. EDA 결과 정리

팀 EDA 핵심 — 대구·경북 법인 11,018곳, 2023.01~2025.12



네 칸이 각각 설계 결정 하나와 연결된다.

패널	보여주는 것	연결된 설계
(a) 왜도	원값 39~123 → 양수만 로그 0 근처	로그 변환 + 계정 보유 법인 한정
(b) SMD	전부 기준선 0.1 밖	성향점수매칭
(c) ϵ^2	등급 0.265인데 지역 0.0004 (p는 둘 다 유의)	효과크기 병행
(d) 무변동	운전자금 73% → 52%	보수적 추정 명시

발견이 설계를 어떻게 바꿨나

EDA 발견	→ 설계 변경
수도권은 자기선택된 특수 표본	→ 대조군을 지역 내부로
금융·보험업은 업종 성격이 다름	→ 표본에서 제외
한도=0인데 대출>0 이 48.6%	→ 소진율 폐기, 로그 증감률 채택
균형패널은 처치군이 크게 줄어들	→ 전체 관측 법인을 주 표본으로
왜도 39~178, 계정 절반이 중앙값 0	→ 로그 변환 + 계정 보유 법인 한정
반올림 격자(고유값 499개), 무변동 73%	→ 보수적 추정임을 명시
카드 2023-01 전부 0	→ 결측 처리
노출 법인이 원래 4배 크고 SMD 0.8	→ 성향점수매칭
규모의 95%가 대출	→ 첫 3개월 예금·대출로 분리
퇴직연금 < 신탁, 주택자금 2열 동일	→ 합산 금지 / 변수 제외
수출 ↔ 영업일수 상관 0.54	→ 달력(영업일수) 통제
대구 ↔ 경북 수출 상관 -0.22	→ 지역별로 따로
지역 수출 ↔ 업종 생산 일치율 57%	→ 업종 생산지수 충격 병행
매달 법인 5%가 교체됨	→ 법인 고정효과, 지속·진입·퇴출 분해

7. 재현 대조

팀 문서에 기록된 기준값 35개를 이번 EDA에서 다시 계산했다.

판정	개수
일치	29
불일치	1
차이(정의 다름)	5

표본·처치 수(11,036 / 11,018 / 1,032 / 523 / 2,692 / 9,528), 소진율 진단 6개, SMD 4개, 외부 변수 상관 7개, 등급 변동 49.5%가 모두 일치했다.

정의 차이 5개는 계산 방식이 달라 생긴 것으로 어느 쪽이 틀린 것이 아니다.

항목	문서	EDA	원인
6개월 무변동	54.2%	52.4%	로그차분(+1) vs 비율
운전자금 = 하위 합	96.1%	95.3%	일치 판정 허용오차
시설자금 = 하위 합	97.9%	97.7%	"
무역금융↔수출 회사 내 상관	+0.09	+0.054	노출 법인만 vs 전체
금융업 요구불 배수	32배	31.7배(전국) / 3.4배(대경)	전국 vs 대구·경북

세부 표는 `out/eda7_검증대조.csv` 에 있다.

8. 확인된 문서 오류·표현 수정 후보

문서	지금	실제	조치
방향성 문서 소진율 진 단표	"한도 > 운전자금 인 행 0.5%"	19.8%(전체) / 48.0%(한도>0 중)	수치 수정
방향성 문서 · CLAUDE.md	금융·보험업이 "전체 통계를 지배", "요구불 32배"	32배는 전국 기준. 대구·경북엔 18곳, 제외 효과 0.3~2.2%	근거 문장 수정
CLAUDE.md	업종 대분류 18개	금융 제외 후 17개	단서 추가

결론은 바뀌지 않는다. 소진율을 버린 근거는 "한도=0인데 대출>0이 48.6%"와 "중앙값 1.000"이고 둘 다 정확히 재현됐다. 금융·보험업 제외도 타당하다. 고칠 것은 근거로 든 수치와 표현이다.

9. 한계

- 이 EDA는 분석 착수 전에 한 번에 이뤄진 것이 아니다. 일부는 분석 중에 발견됐고, 그때마다 설계를 바꿨다. 문서는 6일차 양식에 맞춰 사후에 정리한 것이다.
- 새로 계산한 수치는 기존 결론을 바꾸는 데 쓰지 않았다. 분석 동결(10/2) 원칙에 따라, 기존 설계를 설명하는 자료로만 쓴다.
- 자동 EDA 도구는 쓰지 않았다. 이 데이터의 핵심 문제(구간 문자열, 반올림 격자, 변수 정의 실패, 패널 구조)는 자동 도구가 잡아내지 못한다.
- 원본 데이터는 은행 제공 자료라 외부 서비스에 올리지 않았다. 모든 계산은 로컬에서 수행했다.

부록. 재현 방법

스크립트	내용	소요
eda0_columns.py	원본 70열 이름 확인	수초
eda1_extract.py	EDA용 43열 추출 → parquet	약 13분
eda2_descriptive.py	기술통계·분포·반올림·무변동·입출금	1분
eda3_categorical.py	범주형 빈도·교차표·Cramér's V	1분
eda4_groups.py	그룹별 비교·SMD·박스플롯	1분
eda5_correlation.py	상관·히트맵·외부 변수·Kruskal-Wallis	2분
eda6_multicollinearity.py	변수 정의 검증·VIF	1분
eda7_summary.py	재현 대조·그룹 차이·핵심 4패널	1분
eda8_figures.py	표본 갈때기·분포·패널 구성·충격 시계열	1분

산출물

- 집계표 15개 (out/*.csv)
- 그림 10장 (_build_img/*.png)
- 이 문서

공유하지 않는 것: 원본 엑셀, eda_panel.parquet (파생 패널), out/eda3_회사단위_요약.csv (법인 단위 속성).

수치는 모두 집계 결과이며 법인 단위 값과 법인ID는 포함하지 않는다. 이 문서는 교육 과정의 결과물이며 iM뱅크의 공식 입장이 아니다.