

돈독 프로젝트 — 데이터 전처리 모음

2026-10-03 정리 · 통계프로젝트 + 비즈니스 모델(매칭 모델)에 쓰인 데이터 전부

원칙: 은행 내부 원본 데이터(법인별 익명 거래 원자료, 114MB xlsx)는 제외했다. 다만 그 원본을 가공해서 만든 분석용 데이터(df_ready.csv 등)는 "전처리 결과물"이라 포함했다.

01_외부_원본데이터

은행이 아닌 공개 출처에서 받은 원본·가공 데이터. 전부 외부 통계기관 자료다.

파일/폴더	내용	출처
Kstat_무역통계_원본/	한국무역협회 K-stat 지역별 수출입 원본 엑셀 2개	한국무역협회 K-stat
export_region.csv	대구·경북 월별 수출입 금액·건수, 전월비·전년동월비 (2022.01~2025.12)	관세청·K-stat, K-stat 원자료와 100% 대조 확인
환율_ECOS원자료_202101_202512.csv	원/달러 월평균 매매기준율 (2021.01~2025.12)	한국은행 ECOS
기준금리_ECOS원자료_202101_202512.csv	한국은행 기준금리 월자료 (2021.01~2025.12)	한국은행 ECOS
workdays_2021_2025.csv	월별 영업일수·전년동월차·공휴일 여부 (2021~2025, 전국)	Python holidays 라이브러리(KR)로 계산, 팀 보고서 수치와 대조 재현
production_index_industry.csv	시도×제조업 중분류 광공업생산지수 (2021.01~2025.12)	KOSIS 101_DT_1F02001
지역별_중소기업_수출_quarterly.csv	지역별 중소기업 수출 분기 통계	중소기업중앙회/관련 공식통계
HS4_업종별_수출입_원본/ (217개 파일)	지역×월별 HS4 품목 수출입 원자료 (2022.01~2025.12, 8개 시도)	관세청 수출입무역통계
HS4_업종매핑_concordance/	HS4 품목코드 ↔ 업종분류 매핑표(CPC21-HS2017, ISIC4-CPC21)	UN 국제표준분류 대조표
외부데이터_출처설명.md	위 ECOS·KOSIS·영업일수 데이터의 검증 절차·일치 확인 기록 원문	Don-Ddok_Data 저장소 README

02_은행데이터_전처리결과(df_ready)

df_ready.csv — iM뱅크 법인 원자료(제외 대상)에 공식 수출통계·영업일수·환율을 결합해서 만든 **분석용 통합 패널**.
대구·경북 법인 11,036곳 × 36개월(2023-01~2025-12). REPORT.md·최종보고서의 모든 회귀분석이 이 파일
하나에서 시작된다. 원본 거래 레코드가 아니라 월별 집계·가공이 끝난 분석용 테이블이라 포함했다.

03_매칭모델_산출데이터

상품 매칭 모델(세그먼트·페르소나·추천)이 df_ready.csv를 가공해서 만든 결과물.

파일	내용
persona_firm_month.csv	법인×월별 세그먼트·페르소나 분류 결과 (가장 큰 파일, 원천 데이터)
persona_snapshot_202512.csv, persona_trend.csv, persona_demand_median.csv	특정 시점 스냅샷·추이·계정별 중앙값 요약
recommend_firm_month.csv	법인×월별 상품 추천 결과 (원천 데이터)
recommend_demo_202507.csv, recommend_summary_*.csv	데모용·요약용으로 가공한 추천 결과
trigger_stages.csv	월별 국면(관찰·적기·정점유지·장기둔화) 판정 결과
stage3_before_metrics.json, stage3_compare_metrics.json	매칭모델 3단계 개선 전후 비교 지표
demo_data.json, live_data.json	데모 화면(index.html)이 읽어가는 최종 가공 데이터

04_상품데이터

iM뱅크 웹사이트에 공개된 기업상품 페이지를 크롤링·정리한 데이터(고객 거래정보 아님).

파일	내용
기업상품.csv, 기업상품_매핑.csv	iM뱅크 기업상품 55개 목록과 페르소나별 매핑
product_rules.yaml	국민x페르소나별 상품 추천 규칙
imbank_product_links.csv, imbank_product_pages.csv, imbank_product_tables.csv, imbank_product_404.csv	크롤링 중간 산출물(링크 목록, 페이지 원문, 표 추출, 접근 실패 페이지 로그)

05_분석별_전처리및결과표

df_ready.csv 하나로 끝난 게 아니라, 세부 가설마다 따로 판 분석 13갈래가 각자 자기만의 전처리 단계·결과표를 가지고 있다. 폴더별로 "패널 구성(step0류) → 회귀결과(results/judgment) → 강건성 점검(robust/mde/pretrend)" 흐름이 반복된다.

폴더	뭘 보려고 판 분석인지	핵심 파일
01_harmonized/	네 계정(요구불·운전자금·거치식·적립식) 공통 사양 재추정 — REPORT.md의 본체	results_all.csv(전체 결과), judgment.csv(등급 판정), balance_*.csv(계정별 매칭균형), mde.csv(검출력), pretrend*.csv(사전추세)
01_harmonized/addon_multiplicity/	외부 피드백 반영한 추가 재검증 — 허들모형, E23, 다중지표 트리거, 성장모멘텀(폐기), 216억 추정	hurdle_model.csv(계좌보유 vs 잔액수준 분리), multi_indicator_trigger_v2.csv(수출+생산지수), growth_momentum_backtest*.csv(폐기된 개별법인 예측), real_hold_적립식.csv(HOLD 재검증)
01_harmonized/parts/, parts_iter/	계정x모형(C1/C2/E23/POS/HOLD 등)별 개별 회귀 산출물 62개	res_{계정}_{모형}.csv 형태
02_did_demand_deposit/	요구불예금 최초 분석(하모나이즈 이전 버전)	results_table.csv, balance_table.csv
03_did_loan_robust/	운전자금 대출 강건성 점검 14종(부록 C)	results_table.csv, pretrend_joint.csv
04_firm_shock/	법인 자신의 실제 외환실적 변화를 충격으로 쓴 분석	results.csv, step0_tables.csv(표본 구성)
05_industry_shock/	업종별 수출입 충격(HS4→업종 배분)	shock_series.csv, hs4_ksic_weights.csv(품목→업종 가중치), isic4_to_ksic.csv(업종분류 매핑)
06_mechanism_inflow/	입출금 메커니즘 점검(4.5절)	flow_ratio.csv, results.csv
07_trade_extra_mde/, 08_trade_finance_mde/	무역금융·외환 관련 보유 패턴·검출력	step0_*.csv(보유법인 월별 구성), calibration*.csv
09_exploratory/	초기 탐색 단계 가설 후보 전수 검토	step0_candidates.csv, tests_log.csv
10_devreview/	디벨롭 리뷰 단계 번들 점검(a~i) — 데이터 정합성, 동반변화, 페르소나 안정성 등	datasheet_*.csv(변수별 프로파일), bundle_*_*.csv
11_insight/	군집·상품 리프트 분석	cluster_profile.csv, product_lift.csv
12_비교_파트3/	매칭모델 변경 전후 비교	dashboard_rule_compare.csv
13_통합분석/	3계정 통합 국소투영, 지역월 상관 등 종합 정리	lp_3계정.csv, 지역월_상관.csv, 법인_동행.csv

이 폴더 안 파일들은 전부 df_ready.csv(또는 그 중간 버전)를 각 분석 목적에 맞게 추가 가공한 것이지, 은행 원본 거래 레코드가 아니다.

제외한 것

- (iM뱅크) 2026 교육용 법인 익명데이터.xlsx (114MB) — 법인별 익명 거래 원자료. 가공 전 원본이라 제외했고, 이걸 가공한 결과물(02번, 05번)만 포함했다.