

부록 D — 데이터 전처리

돈독 프로젝트 · 백업 자료 · 2026-10-02

D1. 영업일수 보정

수출 YoY(전년동월비)는 영업일수 영향을 받는다 — 영업일 1일당 약 4.46%p씩 움직인다. 그래서 원본 YoY가 아니라 영업일수 효과를 뺀 **보정YoY**를 트리거·회귀 양쪽에서 기준으로 썼다.

검증: 분석용 자체 달력과 팀 배포 달력을 2023-01~2025-12 전 기간으로 대조한 결과 완전히 일치한다 — Pearson $r = 1.000$, 월별 영업일수 차이 0일, 전년동월차 부호가 다른 달 0개. 트리거 엔진과 회귀 분석이 서로 다른 달력 파일을 쓰지만 값이 같아 불일치 위험이 없다.

D2. 금액 단위 통일

원자료의 예금·대출 잔액은 **원 단위**가 기준이다. 이 단위에서 잔액이 0에서 양수로 전환될 때 로그(ln) 변환값이 15~20 구간에서 점프하는 것은 정상 범위다(현업 확인 완료).

반대로 가공 단계에서 단위를 다르게 취급하면(예: 백만원 단위로 오인) 로그 점프가 최대 11 안팎으로 작게 나와 실제보다 효과가 축소돼 보일 수 있다 — 이게 실제로 발생할 뻔한 오류였다. 그래서 모든 로그 변환 단계에서 원 단위로 통일했다.

D3. 이상치 처리

사분위범위(IQR) 기반 **로그-IQR 방법**으로 73개 변수 전체를 점검했다.

한계: 외환실적금액처럼 원래 소액·반올림이 많은 변수는 이 방법이 정상값을 이상치로 잘못 분류할 수 있다는 점을 데이터명세서에 별도로 명시해 뒀다.

D4. 대표값 — 평균 대신 중앙값

요구불예금잔액 기준: **평균 121.4 vs 중앙값 7.4**(표준편차 802.9, 최댓값 75,000). 오른쪽으로 극단적으로 긴 꼬리를 가진 분포라, 평균만 보면 전형적인 법인의 모습을 오해하게 된다. 소수의 초대형 법인이 평균을 끌어올리는 구조라, 대표값은 중앙값을 기준으로 삼았다.

D5. 계정별 0 비중 — 왜 계정마다 분석 방법이 다른가

계정	관측 특징
요구불예금	관측의 90.6%가 양수 — 일반적인 분포 가정 가능
거치식·적립식	관측의 94~95%가 0 — 0↔양수 전환이 변화의 대부분
운전자금 대출	관측의 81.5%가 양수
외환 실적	노출 법인 안에서도 실적 있는 달 44.9%뿐 — 간헐적
패널 연속성	36개월 내내 끊김 없이 관측되는 비율 24.4%

거치식·적립식처럼 94~95%가 0인 변수는 정규분포 가정이 깨지는 전형적인 경우다. 그래서 평균·표준편차 기반 검정 대신 비모수검정(카이제곱, Mann-Whitney, Kruskal-Wallis)을 함께 썼다.

D6. 수출입 기업 기준 (노출 정의)

36개월(2023-01~2025-12) 동안 수출 또는 수입 실적이 한 번이라도 있으면 **수출입 기업**으로 정의했다 → 1,034곳.
나머지 10,002곳은 비수출입 기업으로 비교 대상이 됐다.

시간에 따라 변하지 않는 고정 기준으로 정의한 이유: 만약 "이번 달에 수출하는 기업"처럼 시간가변으로 정의하면, 충격 때문에 거래를 끊은 기업이 수출입 기업 딱지를 잃고 비교군으로 섞여 들어간다(생존편향). 대가로 미래 정보(2025년까지의 실적)를 써야 해서 실시간 운영에는 못 쓴다 — 이 한계는 E23(2023년 실적만으로 재정의) 재검증으로 보완했다.

참고: 11,036곳 자체도 "대구·경북 기업 전체"가 아니라 "iM뱅크와 거래하는 대구·경북 기업"의 거의 전수다.